Практическая работа 4. Кластеризация числовых и текстовых данных

Введение

Цель работы: освоить распространённые методы кластеризации, пригодные для обработки данных разных типов (числовых и текстовых), а также инструменты для извлечения параметров из текстовых данных.

Задачи: требуется выполнить кластеризацию двух самостоятельно сгенерированных выборок входных данных указанных видов. Первая из выборок должна содержать числовые данные (координаты точек), вторая — текстовые данные, для обработки которых требуется предварительно получить набор численных характеристик — признаков. Номера типов входных данных, алгоритмов кластеризации и методов оценки качества кластеризации определяются по номеру варианта из таблицы 1. Пронумерованные описания методов кластеризации, используемых для числовых данных, находятся в таблице 2, методов оценки качества — в таблице 3, генерации численных данных — в таблице 4, текстовых данных — в таблице 5.

Полные коды всех разработанных методов должны быть предоставлены для проверки; требуемые пояснения могут быть даны в виде комментариев к коду или отдельным документом любого нужного формата.

Порядок выполнения работы

Задание 1. По номеру варианта определить из таблицы 1 типы входных данных, которые надо программно сгенерировать для дальнейшей обработки, номера алгоритмов, которые следует применить к этим данным, и методы оценки качества результатов. Из таблицы 2 определить используемый алгоритм кластеризации, из таблицы 3 — метод оценки качества.

Таблица 1. Варианты задания

Номер варианта	Алгоритм	Качество	Точки	Тексты
1	1	4,5	1,2	2
2	2	3,5	1,3	3
3	3	2,4	1,4	4
4	4	2,3	2,3	5
5	5	1,4	2,4	1
6	2	1,3	3,4	2
7	3	4,5	1,2	3
8	4	3,5	1,3	4
9	1	3,4	1,4	5
10	5	2,5	2,3	1
11	3	2,4	2,4	2
12	4	2,3	3,4	3
13	1	1,5	1,3	4
14	5	1,4	1,4	5
15	3	1,3	2,3	1

Номер варианта	Алгоритм	Качество	Точки	Тексты
16	4	1,5	2,4	2
17	1	2,5	3,4	3
18	2	3,4	1,2	4
19	3	2,4	1,3	5
20	5	4,5	1,4	1

Таблица 2. Алгоритмы кластеризации

Номер алгоритма	Описание
1	Метод k-средних (sklearn.cluster.KMeans)
2	DBSCAN (sklearn.cluster.DBSCAN)
3	Affinity propagation (sklearn.cluster.AffinityPropagation)
4	Метод среднего сдвига (sklearn.cluster.MeanShift)
5	BIRCH (sklearn.cluster.Birch)

Таблица 3. Методы оценки качества кластеризации

Номер метода	Описание
1	Rand Index (sklearn.metrics.rand_score)
2	Adjusted Rand Index (sklearn.metrics.adjusted_rand_score)
3	Silhouette Score (sklearn.metrics.silhouette_score)
4	Davies-Bouldin Index (sklearn.metrics.davies_bouldin_score)
5	Взаимная информация (sklearn.metrics.mutual_info_score)

Задание 2. Определить из таблицы 4 виды входных данных, которые должны быть обработаны, и сгенерировать выборку, состоящую из них. В неё должны входить две указанные группы точек пространства без сохранения сведений о номере их типа. Выполнить кластеризацию полученного набора данных несколько раз, изменяя число кластеров (в методах, которые это допускают) либо прочие характеристики близости прецедентов. Оценить устойчивость получаемых результатов при повторных запусках с разными значениями генератора псевдослучайных чисел. Оценить качество результатов всеми нужными методами. Если метод требует наличия эталонной кластеризации, можно взять в качестве номера класса номер группы точек, из которой были сгенерированы примеры из выборки.

Таблица 4. Типы входных данных

Номер типа	Описание
1	Точки вида $(a, b, 0.5 + a + b + \varepsilon)$, где значения a, b, ε — независимые случайные числа, равномерно распределённые на отрезке $[-1, 1]$
2	Точки вида $(a, b + 0.5, a\varepsilon)$, где значения a, b, ε — независимые случайные числа, равномерно распределённые на отрезке $[-1, 1]$
3	Точки вида $(a, b + \varepsilon, 0.5 + a + \varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
4	Точки вида $(a, b, -0.5+b\varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
5	Точки вида $(0.1a-1, 10b, \varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5

Номер типа	Описание
6	Точки вида $(a, 0.1b, 0.1a + 0.2b + 0.1\varepsilon)$, где значения a, b, ε — независимые случайные числа, нормально распределённые со средним значением 0 и среднеквадратическим отклонением 0.5
7	Случайные точки трехмерного пространства, равномерно распределённые по нижнему полушарию с уравнением $x^2 + y^2 + (z + 0.5)^2 = 1, z \leq 0$
8	Случайные точки трёхмерного пространства, лежащие внутри полушария $x^2 + y^2 + z^2 = 1, z \geq 0$ и имеющие в этом объёме равномерное распределение
9	Точки трехмерного пространства вида $(x, y, x^2 + y)$, где значения x — нормально распределенные случайные числа со средним 1 и среднеквадратическим отклонением 1, значения y — случайные числа, равномерно распределенные по отрезку $[-1, 1]$
10	Точки трёхмерного пространства вида $(x, y, e^{x-y} + \varepsilon)$, где x и y — нормально распределённые случайные числа со средним 1 и среднеквадратическим отклонением 3, ε — равномерно распределённые случайные числа из диапазона $[-0.1, 0.1]$

Задание 3. Определить по таблице 4 вид выборки текстовых данных, после чего самостоятельно собрать её, пользуясь любыми доступными источниками (в том числе, при желании, доступными для свободного использования готовыми выборками). В выборке должно быть по 10 примеров текстов каждого из двух указанных классов. Проще всего использовать англоязычные тексты, так как их дальнейшая обработка существенно облегчается благодаря малому числу словоизменений. Размер каждого текста — примерно от 100 до 200–300 слов.

Таблица 5. Типы текстовых выборок

Номер типа	Описание выборки
1	Десять рецептов кондитерских изделий и десять рецептов закусок либо мясных/рыбных блюд
2	Десять положительных отзывов на книги либо фильмы и десять отрицательных отзывов на них
3	Десять фрагментов статей Википедии о растениях и десять — о животных
4	Десять фрагментов газетных/журнальных статей об искусстве (выставках, гастролях и т.п.) и десять — о спорте
5	Десять фрагментов сочинений античных философов и десять — философов Нового времени или более поздних

Задание 4. Кластеризовать текстовую выборку по примеру task4_text_clustering.zip, в котором скрипт test_clustering.py извлекает признаки из текстовой выборки. Допускается использование любого метода извлечения признаков, например:

- sklearn.feature_extraction.text.CountVectorizer;
- sklearn.feature_extraction.text.TfidfVectorizer;
- sklearn.feature_extraction.text.HashingVectorizer.

Применить для кластеризации метод, применённый в задании 2, и какой-либо другой метод по выбору. Сделать вывод об успешности кластеризации тестовой выборки в таком виде.

Попытаться улучшить результаты, вручную повысив сходство текстов каждого из кластеров между собой. Для этого можно, например, добавить в тексты каждой из групп совпадающие слова, заменив ими синонимы. После этого следует повторить кластеризацию, отметить изменения и сделать предположение об их причинах.

Контрольные вопросы

1. Для каких видов данных рассчитать сходство/различие между прецедентами проще, чем значения признаков каждого из них?
2. Почему кластеризация разными способами может привести к разным результатам?
3. Как можно оценивать сходство текстов?